FH Salzburg

Wissenschaftliches Arbeiten und Forschungsmethoden

Datenaufbereitung

kompetent
relevant
nachhaltig

Schritte einer Forschungsarbeit

1. Forschungsthema finden
2. Forschungsstand und theoretischer Hintergrund
3. Untersuchungsdesign
4. Operationalisierung
5. Stichprobenziehung
6. Datenerhebung
7. **Datenaufbereitung**
8. Datenanalyse
9. Ergebnispräsentation

Nach Döring und Bortz (2016)

Datenaufbereitung

Ziel der Datenaufbereitung, S. 585

1. Vollständigkeit
2. Einheitlichkeit (z.B. Datumsangabe)
3. Ausschluss doppelter Datenzeilen
4. Behandlung von fehlenden Werten
5. Behandlung von Ausreißern
6. Plausibilität von Antworten

Die Rohdaten

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
1	id	submitdate	lastpage	startlanguage	seed	startdate	datestamp	SDQ01	SDQ02	SDQ02[other]	SDQ03	SDQ04	BEQ01[SQ01]	BEQ01[SQ02]	BEQ01[SQ03]	BEQ01[SQ04]	BEQ01[SQ05]	BEQ01[SQ06]
2	4			de	1662922956	2024-11-11 14:33:41	2024-11-11 14:33:41											
3	5	2024-11-11 15:12:17	4	de	565018704	2024-11-11 15:08:38	2024-11-11 15:12:17	W	AT		2003	N	1	1	1	3	3	2
4	6	2024-11-11 15:38:34	4	de	78300398	2024-11-11 15:31:52	2024-11-11 15:38:34	M	-oth-	Niede	2004	N	3	3	2	2	3	2
5	7	2024-11-11 17:11:15	4	de	1542003606	2024-11-11 17:05:14	2024-11-11 17:11:15	W	-oth-		1999	N	2	3	2	3	2	2
6	8	2024-11-11 18:59:37	4	de	1577932235	2024-11-11 18:49:18	2024-11-11 18:59:37	M	D		1999	N	2	2	1	4	1	2
7	9	2024-11-11 19:08:00	4	de	1731482461	2024-11-11 19:04:33	2024-11-11 19:08:00	M	AT		2002	N	3	2	3	2	3	2
8	10	2024-11-11 19:25:43	4	de	780299796	2024-11-11 19:22:12	2024-11-11 19:25:43	W	-oth-	Schwe	2002	N	1	3	1	1	1	2
9	11	2024-11-12 11:31:05	4	de	1755617036	2024-11-12 11:26:52	2024-11-12 11:31:05	M	AT		1997	N	1	2	2	2	3	3
10	12	2024-11-12 14:09:41	4	de	1034988533	2024-11-12 14:03:14	2024-11-12 14:09:41	M	AT		2000	N	2	2	1	2	4	3
11	13	2024-11-12 15:09:15	4	de	1057231701	2024-11-12 14:32:27	2024-11-12 15:09:15	M	AT		1999	N	1	3	1	1	1	1
12	14	2024-11-12 18:28:00	4	de	1375664351	2024-11-12 18:23:05	2024-11-12 18:28:00	M	AT		2001	N	3	2	2	3	2	1
13	15	2024-11-12 18:33:21	4	de	939064970	2024-11-12 18:24:38	2024-11-12 18:33:21	W	D		2002	N	3	1	2	4	2	3
14	16	2024-11-12 18:59:23	4	de	768075220	2024-11-12 18:52:31	2024-11-12 18:59:23	M	AT		1998	N	2	3	2	4	1	2
15	17			de	2137165717	2024-11-12 18:59:34	2024-11-12 18:59:34											
16	18	2024-11-12 19:04:27	4	de	45087630	2024-11-12 19:01:07	2024-11-12 19:04:27	W	AT		1997	Y	4	2	2	4	3	1
17	19	2024-11-12 19:09:08	4	de	1522606298	2024-11-12 19:05:09	2024-11-12 19:09:08	W	AT		1997	N	5	2	2	3	2	3
18	20	2024-11-12 19:14:07	4	de	1724319571	2024-11-12 19:08:46	2024-11-12 19:14:07	W	AT		2002		3	2	2	3	3	1
19	21	2024-11-12 20:55:29	4	de	650369996	2024-11-12 20:44:16	2024-11-12 20:55:29	M	AT		1999	N	1	1	1	1	1	1
20	22	2024-11-12 21:46:00	4	de	456693392	2024-11-12 21:35:27	2024-11-12 21:46:00	M	AT		2001	N	1	3	2	2	2	3
21	23	2024-11-12 21:56:39	4	de	857561200	2024-11-12 21:36:01	2024-11-12 21:56:39	M	-oth-	Itali	2004	N	2	2	4	3	5	2
22	24	2024-11-12 21:44:28	4	de	200810499	2024-11-12 21:36:03	2024-11-12 21:44:28	M	AT		2002	N	1	5	2	2	4	2
23	25	2024-11-12 22:23:46	4	de	269498938	2024-11-12 22:16:14	2024-11-12 22:23:46	W	AT		1997	N	2	2	2	3	2	2
24	26	2024-11-12 23:28:52	4	de	1309951381	2024-11-12 23:24:16	2024-11-12 23:28:52	M	AT		2002	N	2	1	2	1	3	2
25	27	2024-11-13 08:56:00	4	de	348892467	2024-11-13 08:52:51	2024-11-13 08:56:00	M	AT		1992	N	2	3	1	1	1	1
26	28	2024-11-13 10:05:35	4	de	1255605794	2024-11-13 10:00:56	2024-11-13 10:05:35	W	AT		1992		1	1	1	1	1	1
27	29			de	2032414825	2024-11-13 10:05:53	2024-11-13 10:05:53											
28	30	2024-11-18 10:01:33	4	de	1361453151	2024-11-18 09:51:51	2024-11-18 10:01:33	M	AT		2002	N	1	2	1	1	1	2
29	31	2024-11-18 09:56:56	4	de	1681255945	2024-11-18 09:53:26	2024-11-18 09:56:56	W	AT		1998	N	2	3	1	3	1	1
30	32	2024-11-25 11:59:22	4	de	440670575	2024-11-25 11:56:36	2024-11-25 11:59:22	M	AT		2001	N	2	2	1	3	2	1
31	33	2024-11-30 09:20:53	4	de	829997553	2024-11-30 09:14:31	2024-11-30 09:20:53	W	-oth-	Phili	2001	Y	3	4	1	2	2	1
32																		
33																		

Abbildung 1: Die Ausgangslage: Datenmatrix

- Anzahl Datenzellen: $N \times V$
- Hier: Rückläufer (N) = 29, Variablen (V) = 42. 1218 Datenpunkte!

Ordnung im Chaos, der Codeplan

- Enthält eine Auflistung wie Variablen mit ihren Ausprägungen zu interpretieren sind
- Was bedeutet Codierung in Rohdaten?

	H	I	J	K	L	M	
	SDQ01	SDQ02	SDQ02[bther]	SDQ03	SDQ04	BEQ01[SQ01]	BE
1							
7	W	AT		2003	N	1	1
8	M	-oth-	Niede	2004	N	3	3
5	W	-oth-		1999	N	2	3
7	M	D		1999	N	2	2
0	M	AT		2002	N	3	2
3	W	-oth-	Schwe	2002	N	1	3
5	M	AT		1997	N	1	2
1	M	AT		2000	N	2	2
5	M	AT		1999	N	1	3
0	M	AT		2001	N	3	2
1	W	D		2002	N	3	1
8	M	AT		1996	N	2	3
1							
7	W	AT		1997	Y	4	2
3	W	AT		1997	N	5	2
7	W	AT		2002		3	2
0	M	AT		1999	N	1	1
0	M	AT		2001	N	1	3
0	M	-oth-	Itali	2004	N	2	2
8	M	AT		2002	N	1	5
5	W	AT		1997	N	2	2
2	M	AT		2002	N	2	1
0	M	AT		1992	N	2	3
5	W	AT		1992		1	1
1							
8	M	AT		2002	N	1	2
5	W	AT		1998	N	2	3
2	M	AT		2001	N	2	2
3	W	-oth-	Phili	2001	Y	3	4

Abbildung 2: Auszug aus Rohdatendatz

Ordnung im Chaos, der Codeplan II

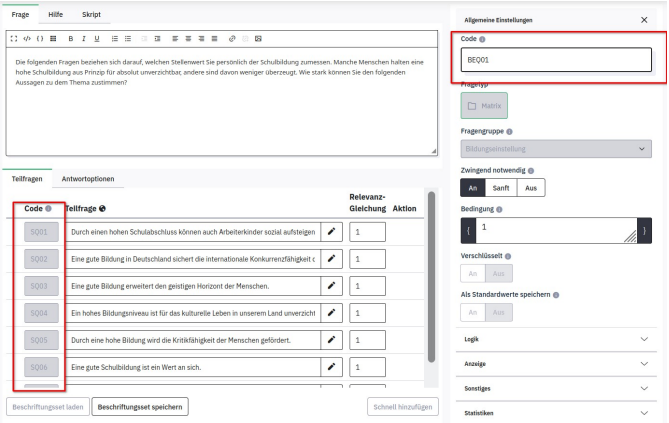

Abbildung 3: Auszug Codierng in Limesurvey

Ordnung im Chaos, der Codeplan III

Abbildung 4: Auszug Codierng in Limesurvey (Antworten)

Ordnung im Chaos, der Codeplan IV

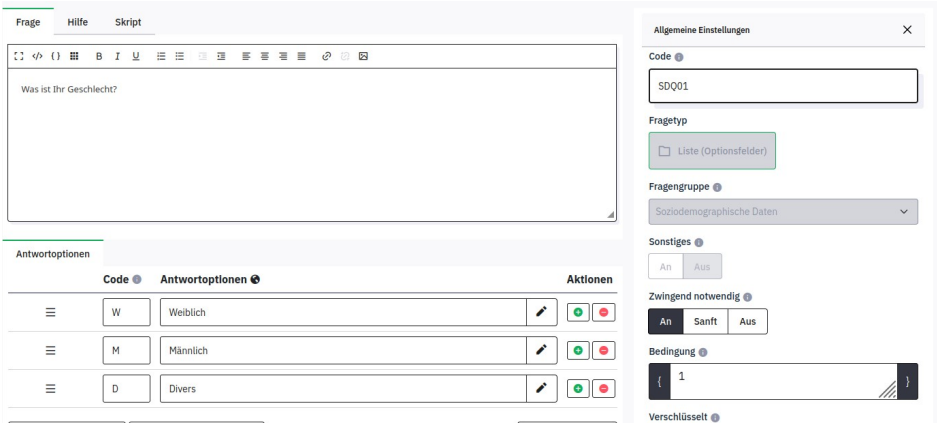

Abbildung 5: Auszug Codierng in Limesurvey (Antworten)

Ordnung im Chaos, der Codeplan V

- **Leben Sie mit einem Partnerin bzw. Partner zusammen?**
- **Durch einen hohen Schulabschluss können auch Arbeiterkinder sozial aufsteigen.**

H	I	J	K	L	M	
SDQ01	SDQ02	SDQ02[other]	SDQ03	SDQ04	BEQ01[SQ01]	BE
L						
7 W	AT		2003	N	1	1
1 M	-oth-	Niede	2004	N	3	3
5 W	-oth-		1999	N	2	3
7 M	D		1999	N	2	2
0 M	AT		2002	N	3	2
3 W	-oth-	Schwe	2002	N	1	3
5 M	AT		1997	N	1	2
L M	AT		2000	N	2	2
5 M	AT		1999	N	1	3
0 M	AT		2001	N	3	2
L W	D		2002	N	3	1
3 M	AT		1996	N	2	3
1						
7 W	AT		1997	Y	4	2
3 W	AT		1997	N	5	2
7 W	AT		2002		3	2
9 M	AT		1999	N	1	1
0 M	AT		2001	N	1	3
9 M	-oth-	Itali	2004	N	2	2
3 M	AT		2002	N	1	5
5 W	AT		1997	N	2	2
2 M	AT		2002	N	2	1
0 M	AT		1992	N	2	3
5 W	AT		1992		1	1
3						
3 M	AT		2002	N	1	2
5 W	AT		1998	N	2	3
2 M	AT		2001	N	2	2
3 W	-oth-	Phili	2001	Y	3	4

Abbildung 6: Auszug aus Rohdatendatz

Ordnung im Chaos, der Codeplan VI

- Übergeordnete Frage (BEQ01): Die folgenden Fragen beziehen sich darauf, welchen Stellenwert Sie persönlich der Schulbildung zumessen. [. . .]
- Frage (SQ01): Durch einen hohen Schulabschluss können auch Arbeiterkinder sozial aufsteigen.
- Antwortoptionen, numerisch:
  - 1: 1 = stimme sehr zu
  - 2: 2
  - 3: 3
  - 4: 4
  - 5: 5 = stimme überhaupt nicht zu
- Mit Limesurvey ist Teil der Arbeit bereits getan, dennoch für Analyse/Bericht notwendige Tätigkeit

Sonderfall, umgedrehte Frage

- Beispiel: Likert-Skala, Frage zu Wohlbefinden, gemeinsame Ausrichtung
  - Heute geht es mir gut (1 = stimmt sehr zu, . . .)
  - Ich bin gut in den Tag gestartet (1 = stimme sehr zu, . . .)
  - **Ich habe schlechte Laune (1 = stimme sehr zu, . . .)**
- Ziel: Gesamtwert für Wohlbefinden ermitteln. Durchschnitt über alle Sub-Fragen nicht direkt möglich
- Bedeutung von Fragen müssen evtl. umgedreht werden
  - Codierung von Frage 3: »1 wird zu 5, 2 wird zu 4, ...«

Sonderfall, umgedrehte Frage II

Items

Nr.	Item	Polung
1	Menschen verschiedener Rassen, Religionen und Nationalitäten würden besser miteinander zurechtkommen, wenn sie einander besuchten und gemeinsame Erfahrungen machten.	-
2	Wir können von anderen Ländern eine Menge Gutes lernen.	-
3	Es wäre gut, wenn immer mehr ausländische Jugendliche jedes Jahr nach Deutschland kämen, um an unseren Bildungsstätten zu lernen.	-
4	Wir sollten jeden Ausländer, der gern in unserem Land leben möchte, willkommen heißen.	-
5	Abgesehen von einigen Ausnahmen sind sich Mitglieder einer nationalen Gruppe ziemlich ähnlich.	+
6	Jede Gruppe oder soziale Bewegung, in der viele Ausländer sind, sollte mit Misstrauen beobachtet und möglichst vom Verfassungsschutz überprüft werden.	+
7	Wenn deutsche Ansichten und Wertvorstellungen, sozusagen die deutsche Lebensweise, von allen Nationen übernommen würden, bedeutete dies das Ende aller Kriege.	+
8	Falls ein einziges Land die Welt regieren sollte, könnte die Bundesrepublik dies besser als alle anderen Nationen.	+
9	Die moralischen Grundsätze der Bundesbürger sind höher als die der Angehörigen fremder Nationen.	+
10	Wenn wir mehr Einwanderer in unser Land lassen, wird das unsere Kultur bereichern.	-
11	Es wäre gefährlich für die Bundesrepublik, zu eng mit Nationen zusammenzuarbeiten, die anders sind als wir.	+
12	Die schlimmste Gefährdung der deutschen Kultur während der letzten 50 Jahre ging von fremden Ideen und Agitatoren aus.	+

Abbildung 7: Beispiel von unterschiedlichen Polungen

Anonymisierung von Daten

- Bei Online-Fragebögen leichter zu erreichen
- Achtung bei seltenen Ausprägungen
  - Einziger Südtiroler in Stichprobe?
  - Einzige Pferdebesitzerin in Stichprobe?
- Wenn möglich: Seltene Merkmale daher nicht erfassen
- Außerdem: IP-Adressen nicht protokollieren

Datenbereinigung

- Prüfung Wertebereich
  - Geburtsjahr, (> 1970?, < 2005?), Kurzantworten: 94 statt 1994
- Plausible Antworten
  - Anzahl Kinder: 111?
- Extremwerte
  - 1% sagt ja, 99% nein? Zumindest vermerken
- Lösung: Entweder Daten ausschließen oder korrigieren
- Wichtig: Niemals den Rohdatensatz verändern! Änderungen dokumentieren!

Datentransformation, fehlende Werte

- Gründe sind vielfältig. Frage übersehen, Frage bewusst unbeantwortet
- Evtl. treten Auslassungen bei bestimmten Gruppen gehäuft auf (z.B. Gehaltsangaben und sozioökonomischen Status)
- Einzelne fehlende Werte sind (bei hoher Anzahl an Rückläufer) unproblematisch
- Lösungen
  - Schätzung mittels statischem Modell oder Mittelwert
  - Oder einfacher Auslassung bei Berechnung

Datentransformation, Umpolung

- Intuitiv erfassbare Bedeutung von Zahl (je höher, desto *mehr*)
  - Beispiel Glück: Hoher Wert bedeutet viel Glück
- Erfordert unter Umständen Umpolung, weil Antwortoptionen anders gecodet sind (Ähnlichkeit zu umgedrehten Fragen)

Datentransformation, Bildung neuer Werte

- Likert-Skala enthält mehrere Fragen die Gesamtwert bilden
  - Jede Frage wird mit Zahlenwert (laut Code-Tabelle + Umpolung) versehen
  - Bildung von Durchschnitt über alle Werte

Eine Schlussbemerkung

- Sauberes wissenschaftliches Arbeiten erfordert, dass jeder Teilschritt dokumentiert und begründet ist
- Rohdaten bleiben erhalten, damit Arbeitsergebnisse nach geprüft werden können
- Wir arbeiten später mit RMarkdown, welches uns genau das ermöglicht!

Vielen Dank für Eure Aufmerksamkeit!

Literatur

Döring, Nicola, und Jürgen Bortz. 2016. *Forschungsmethoden und Evaluation in den Sozial- und Humanwissenschaften*. Springer-Lehrbuch. Berlin, Heidelberg: Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-642-41089-5.